Домашнее задание 2

Important notice

1) **Вы не сможете приступить к выполнению ДЗ №2, пока не выполните хотя бы минимум из ДЗ №1**. Поэтому если вы в ДЗ №1 не получили работающий master-хост с инициализацей структуры БД - делать задание №2 нет никакого смысла. Лучше посмотрите первые занятия, сделайте ДЗ №1 и обратитесь при необходимости за помощью/консультацией.
2) **Это задание выполняется и оценивается индивидуально или в группах до 4 человек!** Если вы используете код из открытых источников (репозитории ваших одногруппников таковыми не считаются) - пожалуйста, указывайте ссылки на них (можно в readme вести лог всех источников, откуда вы берете код). Находить готовые рецепты в интернете - хорошо, списывать - плохо.
3) **При обнаружении списывания (одинаковый код в двух репозиториях без указания внешнего источника) оценка будет выставляться студенту (группе), чей коммит с решением был первый**. Остальным - 0 баллов и докладная в УО.
4) Чтобы исключить возможность списывания, **рекомендуется сделать ваш репозиторий с домашним заданием приватным**.

Формулировка

У нас есть поисковик дешевых авиабилетов.
БД системы, которая содержит информацию о забронированных с его помощью билетах, выглядит следующим образом:

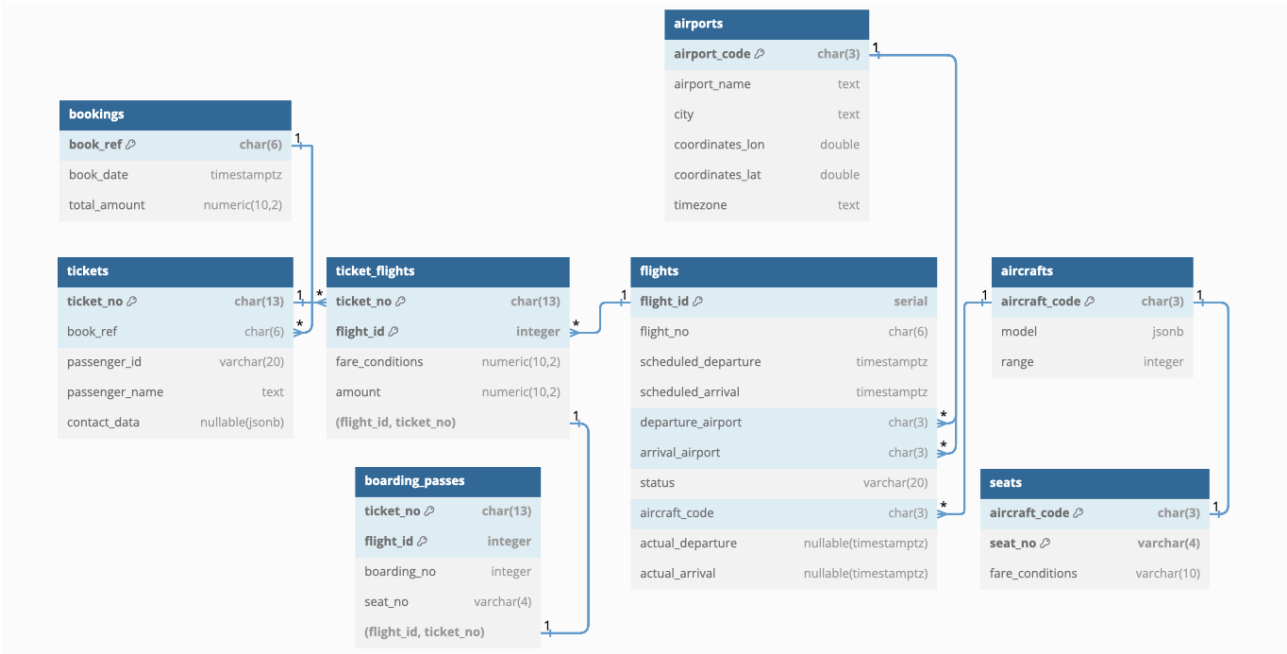

Это мы уже с вами видели в ДЗ №1.
Сейчас мы имеем:
* master-хост с БД
* async-replica, на которую копируются данные для аналитической нагрузки

Задача:

1. **Выбрать одну из предложенных архитектур** для реализации детального слоя DWH: **Data Vault, Data Vault 2.0 или якорная модель**. Обосновать выбор архитектуры в README
2. **Написать DDL** для вашего детального слоя DWH (если ваша реализация этого требует - об этом см. далее)
   Составить ER-диаграмму для детального слоя DWH (а вот этот пункт уже

обязательный; можно воспользоваться специальными сервисами для построения диаграмм, когда ваше DWH уже будет готово, или построить диаграмму по DDL из п. 1)
Поднять еще один инстанс PostgreSQL для DWH и инициализировать его полученной выше структурой
Данные детального слоя необходимо **сложить в схему dwh_detailed.**
Важно:
- помните, что системы-источники также являются сущностями в терминах DWH
- помните, что DWH по определению insert-only, у нас не должны использоваться операции update и delete
- помните про версионирование данных
- помните, что в dwh существуют конвенции нейминга для таблиц и полей, а также - технические поля (sourceSystemId, createdAt и другие)
- DataGrip и draw.io из коробки умеют строить ER-диаграммы из структуры в sql-файле

3. **Поднять и подключить debezium** к master-хосту вашего сервиса
4. **Реализовать на python (или другом ЯП) DMP-сервис**. Его задача:
   1. Читать данные об изменениях в таблицах сервиса из kafka
   2. Формировать данные для добавления в DWH
   3. Осуществлять вставку данных в DWH
5. **Посадить DMP-сервис в контейнер** в Docker-compose

Бонусные задания:
1. **Использование генератора кода для создания DDL** детального слоя (не важно, opensource или самописного, главное - чтобы он принимал config-файл на вход, а на выходе выдавал sql-файл для создания таблицы). Принцип работы необходимо описать и продемонстрировать в README
2. **Использовать для DWH** не PostgreSQL, а масштабируемое решение - **MPP-базу или стек Iceberg+S3**. Обосновать выбор в README
   Важно:
   - помните, что не все MPP могут эффективно работать с большим кол-вом JOIN (например, ClickHouse), и это надо учитывать при выборе СУБД и/или архитектуры DWH
   - помните, что для эффективной обработки данных в MPP могут потребоваться сортировка/сегментация по ключам
   - помните, что S3 предоставляет вам только хранение, и для обработки данных вам также потребуется compute engine (Spark, Trino, DuckDB или другие)
3. **Использовать в DMP один универсальный класс и yaml-конфиги** вместо отдельных классов для каждой таблицы. Принцип работы необходимо описать и продемонстрировать в README
   Важно:
   - в пунктах 1 и 3 бонусного задания можно использовать dbt (подробнее о dbt - на занятии 7)
   - при использовании dbt писать ddl для детального слоя не нужно - можно просто привести финальную схему

Сроки

Важно: домашнее задание очень объемное! За один день его сделать вряд ли получится. Времени дается на выполнение много, приступайте к выполнению ДЗ заранее.

1. Дедлайн на 100% - 4 недели - **24.11.2024 23:59:59 включительно**
2. Дедлайн на 75% - до дедлайна следующего ДЗ
3. Дедлайн на 50% - до конца курса

Как сдавать ДЗ?

- Готовое ДЗ загружается на GitHub (в приватный репо + выдать мне доступ - @mgcrp)
- Домашнее задание №2 можно продолжать делать в том же репозитории, что и домашнее задание №1 (можно для связанности отвести отдельную ветку)

- К репо должен быть приложен README.md с описанием того, что вы сделали и как это запустить
- Задание сдается в форму: https://forms.gle/ZuVuoGdGCVhaaXmm7

Критерии оценки

Балл	Критерий
4	DDL для детального слоя DWH ER-диаграмма Поднят новый инстанс PostgreSQL для DWH, он инициализируются со структурой детального слоя
6	Поднят, подключен и работает debezium
10	Реализован и работает DMP, происходит наполнение детального слоя DWH
+2 балла	Использование генератора кода для создания DDL детального слоя
+4 балла	Использование для DWH не PostgreSQL, а MPP/S3 по вашему выбору
+4 балла	Реализовать DMP как один универсальный класс и yaml-конфиги вместо отдельных классов для каждой таблицы (или dbt)
+2 балла	Выполнение домашнего задания в одиночку

Максимальный балл за ДЗ - 22

Как это будет проверяться?

1) **Запуск системы по инструкции** из вашего README
2) **Проверка работы реплики**
   Автотест: python-скрипт, который создает синтетические данные и пишет их в master, после проверяет, что все сгенеренные данные попали в реплику
3) **Проверка работы debezium**
   Автотест: проверяет, что для таблиц создались топики в kafka, в них пишутся данные
4) **Проверка работы DMP**
   Автотест: проверяет, что данные успешно пишутся в таблицы детального слоя DWH
5) Ручная проверка бонусов и VIEW